Analyse Stochastique de la Fiabilite d'un Cluster NVIDIA H100

Aarab Ayoub

Encadrant: Pr. Abdellatif El Afia

4 avril 2026

Short description

Objectif : modeliser, estimer et optimiser la fiabilite d'un cluster GPU H100 avec un cadre probabiliste unifie.

Slide 2 – Problem & Motivation

- Pannes frequentes en entrainement LLM a grande echelle.
- Etat reel du GPU non observable directement.
- On observe temperature, ECC, XID, puissance.

Interpretation : Sans modele probabiliste, la maintenance devient reactive et couteuse.

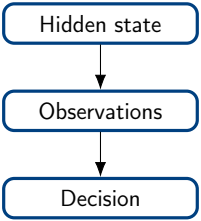

Slide 3 – DTMC Model

Models discrete evolution of system states

Le DTMC decrit les transitions pas-a-pas entre Healthy, Degraded, MaintenanceRequired, FailedRecoverable et FailedPermanent.

$$P = \begin{pmatrix} 0.90 & 0.06 & 0.02 & 0.01 & 0.01 \\ 0.15 & 0.70 & 0.10 & 0.05 & 0.00 \\ 0.40 & 0.00 & 0.40 & 0.15 & 0.05 \\ 0.35 & 0.00 & 0.20 & 0.40 & 0.05 \\ 0.00 & 0.00 & 0.00 & 0.00 & 1.00 \end{pmatrix}$$

Interpretation : Used to estimate failure dynamics de facon simple et interpretable.

Slide 4 – DTMC Result (IMPORTANT)

MTTF result

$$\mathrm{MTTF}_{Healthy \to FailedPermanent} \approx 78.93 \text{ pas}$$

- Mesure calculee depuis la matrice de transition executable.
- C'est le temps moyen avant panne permanente.

Interpretation : Le systeme degrade progressivement avant defaillance finale.

Slide 5 – CTMC Model

Continuous-time modeling using transition rates

Le CTMC remplace les probabilites par des taux instantanes dans une matrice generatrice A.

$$A = \begin{pmatrix} -0.10 & 0.06 & 0.02 & 0.01 & 0.01 \\ 0.15 & -0.30 & 0.10 & 0.05 & 0.00 \\ 0.40 & 0.00 & -0.60 & 0.15 & 0.05 \\ 0.35 & 0.00 & 0.20 & -0.60 & 0.05 \\ 0.00 & 0.00 & 0.00 & 0.00 & 0.00 \end{pmatrix}$$

Interpretation : On modelise le temps reel, pas seulement des etapes discretes.

Slide 6 – CTMC Result

- La probabilite de rester operationnel baisse avec le temps.
- La courbe est issue de $P(t) = e^{At}$.

Interpretation : Le risque cumule augmente meme sans choc brutal visible.

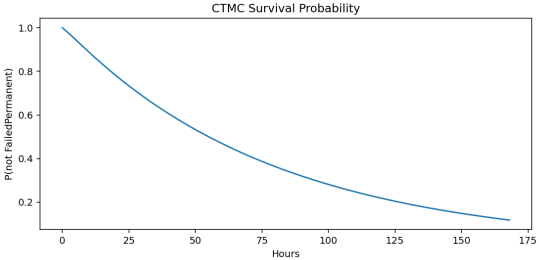

Slide 7 – Stationary Distribution

Long-term behavior of system

$$\pi \approx (0.722,\ 0.144,\ 0.048,\ 0.054,\ 0.032)$$

$$\text{Uptime long terme} \approx \pi_{Healthy} + \pi_{Degraded} \approx 0.866$$

- La distribution stationnaire resume le regime de long terme.

Interpretation : Le systeme reste operationnel la plupart du temps (environ 86%).

Slide 8 – HMM Concept

- Etat latent non directement observable.
- Observations : temperature, ECC, XID, puissance.
- HMM relie etat cache et mesures.

Interpretation : On transforme des signaux bruites en estimation de sante.

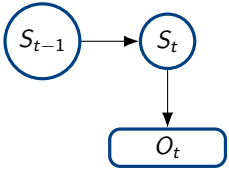

Slide 9 – Forward Algorithm

Forward = probability / filtering

$$\alpha_t(j) = \left(\sum_i \alpha_{t-1}(i) a_{ij} \right) b_j(o_t)$$

$$P(S_t = j \mid O_{1:t}) = \frac{\alpha_t(j)}{\sum_k \alpha_t(k)}$$

- Calcule la croyance sur chaque etat a chaque instant.

Interpretation : Le Forward donne une probabilite, pas une classe unique.

Slide 10 – Viterbi Algorithm

Best path reconstruction

$$\hat{s}_{1:T} = \arg\max_{s_{1:T}} P(s_{1:T}, o_{1:T})$$

- True state = ground truth simule.
- Viterbi state = sequence inferee.

Interpretation : Viterbi reconstruit la trajectoire la plus plausible des etats caches.

Slide 11 – HMM Result

- Posterior Forward suit les changements de regime.
- true_state et viterbi_state sont proches dans les zones stables.

Interpretation : Le HMM reconstruit correctement les regimes latents dominants.

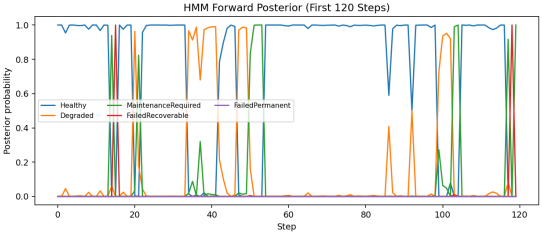

Slide 12 – MDP Model

Decision-making under uncertainty

$$V^*(s) = \max_a \left[R(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V^*(s') \right]$$

- Le MDP choisit l'action qui maximise valeur immediate + valeur future.

Interpretation : Politique optimale = regle de decision par etat de sante.

Slide 13 – MDP Result (IMPORTANT)

Policy table : state → action

Etat	Action optimale
Healthy	keep_running
Degraded	power_cap
MaintenanceRequired	isolate_maintain
FailedRecoverable	reboot
FailedPermanent	isolate_maintain

Interpretation : Chaque etat a une action cible claire et operationnelle.

Slide 14 – Reinforcement Learning

Learning without knowing the model exactly

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[r + \gamma \max_{a'} Q(s',a') - Q(s,a) \right]$$

- Q-learning et SARSA apprennent par interaction.
- Pas besoin d'un modele parfait en entree.

Interpretation : RL complete le MDP quand le monde reel est partiellement connu.

Slide 15 – RL Results

Methode	Retour moyen
Q-learning	63.87
SARSA	67.21

Interpretation : L'agent apprend un comportement performant ; SARSA est legerement meilleur ici.

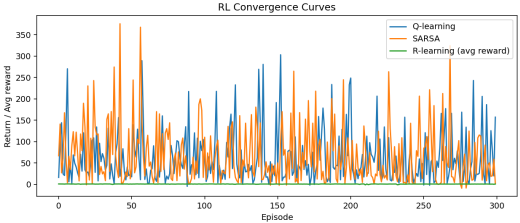

Slide 16 – POMDP / Non-Markov

Handles uncertainty and memory

$$b_{t+1}(s') = \eta\, O(o_{t+1} \mid s', a_t) \sum_s T(s' \mid s, a_t) b_t(s)$$

$$z_t = (\tau_t, c_t) \quad \text{(age + cumul ECC)}$$

- POMDP : decision sur croyance.
- Non-Markov : le risque depend aussi de l'historique.

Interpretation : Plus d'incertitude et de memoire = politique plus prudente.

Slide 17 – Final Insights

- DTMC/CTMC : dynamique de fiabilite.
- HMM : estimation d'etat latent.
- MDP/RL : decision et apprentissage.

Interpretation : Un seul pipeline : **DTMC** $\rightarrow$ **HMM** $\rightarrow$ **MDP** $\rightarrow$ **RL**.

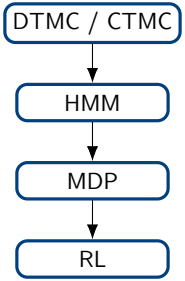

Slide 18 – Conclusion

What we learned

- Fiabilite quantifiee : MTTF $\approx$ 78.93.
- Etat latent estimable via HMM.
- Decision robuste via MDP + RL.

Why this approach is powerful

Cadre unique, interpretable et extensible pour passer de la prediction a l'action.

Next step : calibration sur telemetrie reelle DCGM/XID.