

TP1 : Systèmes de recommandation

Objectifs : Implémenter un système de recommandation.

Exercice : Système de recommandation

Dans cet exercice, nous allons écrire un système de recommandation de film.

Question 1.a. Rendez-vous sur le [site de MovieLens](#) et téléchargez le fichier `ml-latest-small.zip`.

Question 1.b. Écrire une fonction `load_data()` qui :

- Charge les données du fichier `ratings.csv` à l'aide de Python.
- Prend la liste des utilisateurs et films uniques.
- Associe un identifiant unique (et commençant à zéro) à chaque utilisateur et objet.
- Initialise la matrice d'utilité avec des zéros (on utilisera numpy), puis la remplit avec les notes.

On retournera la matrice d'utilité.

Question 1.c. Pour cet exercice, nous allons considérer que la mesure de similarité est la similarité cosinus. Écrire une fonction `get_similarities(utility)` retournant la matrice de tous les produits vectoriels d'utilisateur, la matrice de tous les produits vectoriels de films, un vecteur avec l'inverse des normes de tous les films, et un vecteur avec l'inverse des normes de tous les objets. On fera bien attention de ne pas faire de boucle, mais plutôt d'utiliser des opérations matricielles.

Question 1.d. Écrivez deux fonctions `rank_users(id_user, similarities, inv_norm)` et `rank_items(id_movie, similarities, inv_norm)` qui retourne le classement de tous les utilisateurs (ou films) selon leur score de similarité. Le format de la sortie sera une liste de couple (user, similarité) ou (item, similarité).

Question 1.e. Écrivez les fonctions `recommend_user_based_item(id_user, id_item, utility, similarities, inv_norm, k=10)` qui prédit le score pour un utilisateur et un objet donné avec une approche basée sur l'utilisateur. Pour le score, nous utiliserons la moyenne pondérée.

Question 1.f. De même, écrivez `recommend_item_based_item(id_user, id_item, utility, similarities, inv_norm, k=10)`.

Question 1.g. Modifiez la fonction `load_data()` pour séparer le dataset en un jeu d'entraînement et de test. Pour cela, on pourra mélanger les lignes (`df.sample(frac=1)`) puis mettre les 80% premières lignes dans le train, et le 20% restant dans le test. Le train servira à construire la matrice d'utilité. Le test sera transformé en une liste de (userId, movieId, rating). On retournera maintenant un couple : la matrice d'utilité et la liste des tests.

Question 1.h. Implémentez une fonction `get_rmse_user_based(test_set, utility, similarities, inv_norm, k=10)` qui calcule la RMSE pour l'approche basée sur l'utilisateur. De même, implémentez `get_rmse_item_based(test_set, utility, similarities, inv_norm, k=10)` pour l'approche basée sur l'objet. Comparez les résultats.

Question 1.i. Écrivez un méthode `get_ndcg_at_k_user_based(test_set, utility, similarities, inv_norm, k=10, k_ndcg=10)` qui calcule le NDCG@K en utilisant une approche basée sur les utilisateurs. Pour ce faire, on appliquera l'approche naïve consistant à parcourir tous les utilisateurs du test set, prédire un score pour chaque objet, et classer en fonction de ces scores.

Cette méthode naïve devrait être très longue à calculer. Vous pouvez accélérer les calculs en précalculant pour chaque utilisateur les utilisateurs les plus proches.

Question 1.j. De même, écrivez un méthode `get_ndcg_at_k_item_based(test_set, utility, similarities, inv_norm, k=10, k_ndcg=10)` qui calcule le NDCG@K avec une approche basée sur les objets.

Question 1.k. Nous allons implémenter l'approche basée sur un modèle à l'aide de l'algorithme SVD. Pour cela, écrivez une fonction `get_rmse_svd(test_set, utility, N=100)` qui calcule la RMSE de l'approche SVD. À noter que dans Numpy, pour SVD, il faut restreindre manuellement les matrices au rang k souhaité (en enlevant des colonnes à U, S, et V).

Question 1.l. Faites varier le rang k pour trouver le k avec le RMSE minimal.

Question 1.m. De même, écrivez la fonction `get_ndcg_svd(test_set, utility, k_ndcg=100, N=100)` qui calcule le NDCG dans le cadre de l'approche avec SVD. Notez que la vitesse d'exécution est bien plus rapide qu'avant.

Question 1.n. Afficher les scores de prédiction. Que remarquez-vous ?

Question 1.o. Pour résoudre ce problème, enlever la moyenne des notes sur le jeu d'entraînement aux valeurs connues uniquement. Modifier la fonction `load_data` en conséquence. Est-ce que cela améliore les performances ?