

Compte-rendu de TP : Traitement d'Image et Classification

AARAB Ayoub

31 mai 2025

1 Introduction

Ce TP avait pour objectif d'explorer différentes approches de traitement d'image et de classification, allant des techniques classiques aux méthodes d'apprentissage automatique plus avancées. Nous avons travaillé sur un dataset de feuilles (Leaf Images) en implémentant successivement :

- Un traitement d'image classique avec OpenCV
- Une classification avec différents algorithmes de machine learning
- Un perceptron multicouche (MLP)
- Un réseau de neurones convolutif (CNN)

2 Partie 1 : Traitement d'Image Classique

2.1 Création d'images

Nous avons généré trois types d'images de base :

- Une image RGB bleue (dimensions 256x256)
- Une image en niveaux de gris avec un dégradé horizontal
- Une image binaire avec un carré blanc centré

2.2 Analyse d'images réelles

Pour une image du dataset (3072x3072 pixels) :

- L'histogramme des couleurs montre une distribution bimodale
- Normalisation des valeurs entre 0 et 1 (min=0.0, max=1.0)
- Modification de pixels : ajout d'un carré rouge (50x50)

2.3 Transformations appliquées

- Conversion en niveaux de gris
- Seuillage binaire (seuil=127) et détection de contours (Canny)
- Débruitage : filtres gaussien (7x7) et médian (5x5)
- Opérations morphologiques : dilatation et érosion (noyau 5x5)
- Compression : JPEG (qualité 90) et PNG (sans perte)

3 Partie 2 : Machine Learning Classique

3.1 Extraction de caractéristiques

Pour chaque image (128x128), nous avons extrait :

- Histogramme HOG (128 dimensions)
- Histogramme de couleurs RGB (8 bins par canal)
- Motifs LBP (Local Binary Patterns)
- Descripteurs SIFT (moyenne des 128-d)

3.2 Résultats de classification

Performance des différents classifieurs (accuracy) :

Modèle	Accuracy (%)
SVM	63.00
Random Forest	71.50
k-NN	56.17
Naive Bayes	19.17
Régression Logistique	56.00
Gradient Boosting	70.83

TABLE 1 – Comparaison des performances des classifieurs

Le Random Forest a obtenu les meilleures performances avec 71.5% de précision. La matrice de confusion montre une bonne reconnaissance des classes 0, 3, 4, 6, 7 et 9, mais des difficultés pour distinguer certaines classes similaires.

4 Partie 3 : Perceptron Multicouche (MLP)

4.1 Architecture

- Couche d'entrée : 16384 neurones (128x128 pixels aplatis)
- Couches cachées : 128 et 64 neurones (ReLU)
- Couche de sortie : 10 neurones (softmax)
- Dropout : 0.2 (première couche), 0.2 (deuxième couche)

4.2 Résultats

- Accuracy : 66%
- Meilleure performance sur la classe 7 (precision=0.78, recall=0.83)
- Performance comparable au Random Forest mais avec temps d'entraînement plus long

5 Partie 4 : Réseau de Neurones Convolutionnel (CNN)

5.1 Architecture

- 3 blocs convolutionnels (32, 64, 128 filtres)
- MaxPooling après chaque bloc
- Dropout progressif (0.25, 0.25, 0.4)

- Couche fully-connected finale (128 neurones)
- Data augmentation : rotation (20°), redimensionnement aléatoire

5.2 Résultats

- Accuracy : 91.35% (meilleur modèle)
- Temps d'entraînement : 50 epochs
- Très bonne généralisation grâce aux opérations convolutionnelles

6 Comparaison et Conclusion

Approche	Accuracy (%)	Avantages/Inconvénients
Random Forest	71.50	Rapide, interprétable mais features manuelles
MLP	66.00	Meilleure abstraction mais lent, sensible au bruit
CNN	91.35	Meilleures performances mais complexe, besoin de beaucoup de données

TABLE 2 – Synthèse comparative des approches

En conclusion :

- Les méthodes classiques (Random Forest) donnent de bons résultats rapidement
- Le MLP n'a pas apporté d'amélioration significative dans notre cas
- Le CNN s'est révélé être la meilleure approche avec 91.35% de précision
- Pour améliorer : augmenter le dataset, optimiser les hyperparamètres, essayer des architectures CNN plus avancées